烟台大学 YANTAI UNIVERSITY

基于强化学习的黑白棋的设计与实现

Design and Implementation of Othello Based on Reinforcement Learning

Zhao Qian

Adviser: Wang Jianhua

Yantai University
School of Computer and Control Engineering

2019.05.30

烟台大学 YANTAI UNIVERSITY

Why Reversi and Prior Work

Why Reversi?

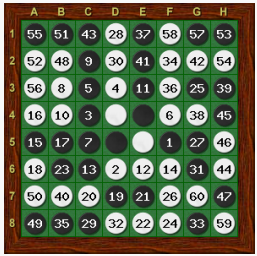

- 以往算法的设计中大都使用博弈树搜索的方法
- 2017 年 AlphaGo Zero 出现了
- 打算将这种思路扩展到黑白棋中

Prior Work

Minimax Tree Search + Alpha-Beta pruning

- 搜索空间巨大（随搜索层数指数级增加）
- 棋力受限于搜索的层数（理想时间内很难提高）
- 棋力受限于设计者的能力（如估值函数的设计）

Monte Carlo Tree Search

- 无需任何领域知识便可工作
- 非对称式增长，算法会频繁地访问“更感兴趣”的节点，并聚焦搜索空间于更加相关树的部分
- 算法可在任何时间终止，并返回当前最优的估计

Reversi: Basic Rules

How to play

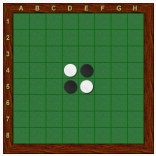

- 棋盘 8×8 大小
- E4、D5 为黑棋
- D4、E5 为白棋
- 执黑先手

- 落子必须在一空位
- 落子必须造成翻转
- 无子可走则本轮 pass
- 有子可走则必须走棋

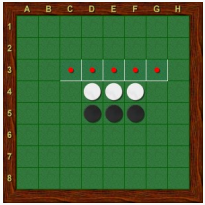

How to win

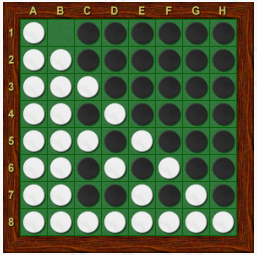

获胜条件：

1. 双方都无子可下
2. 棋子数目多者获胜，若相等为平局

Reinforcement Learning

强化学习解决一类序贯决策问题，它不关心输入的数据长什么样子，它只关心当前采取什么样的行动才能使得最终的回报最大

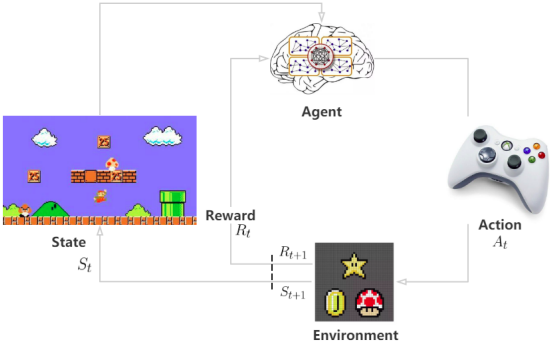

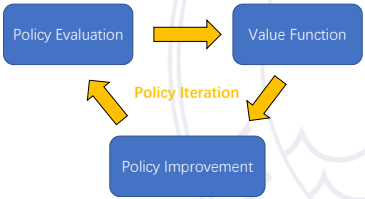

Structure Breakdown

神经网络 f_θ (predict)

$$(\vec{p}, v) = f_\theta(s)$$

- $\vec{p}_\theta(s_t)$: 当前玩家在状态 s_t 下选择每个动作的概率
- $v_\theta(s_t)$: 当前玩家在状态 s_t 下获胜的概率估计

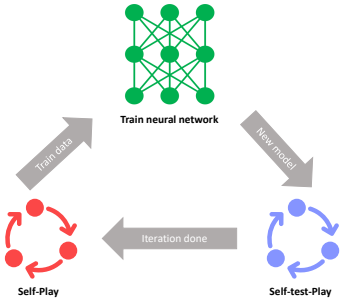

Policy Evaluation

$f_\theta(s) \xrightarrow{(\vec{p}, v)} \text{MCTS} \xrightarrow{\vec{\pi}_t} action$

到达终止态 s_T 获得本局胜利者 Z

Policy Improvement

通过 self play 得到一组 train data

使用 train data 训练神经网络得出新 model

新旧 model 进行对抗判断胜率是否超过阈值需要更新

Neural Policy and Value Network

神经网络 f_θ (train)

Input: train data $(s_t, \vec{\pi}_t, z_t)$

ToDo: 最小化 $\vec{p}_\theta(s_t)$ 与 $\vec{\pi}_t$，$v_\theta(s_t)$ 与 z_t 间的差距

$$Loss = \sum_t (v_\theta(s_t) - z_t)^2 - \vec{\pi}_t \cdot \log(\vec{p}_\theta(s_t))$$

NNet Structure (CNN)

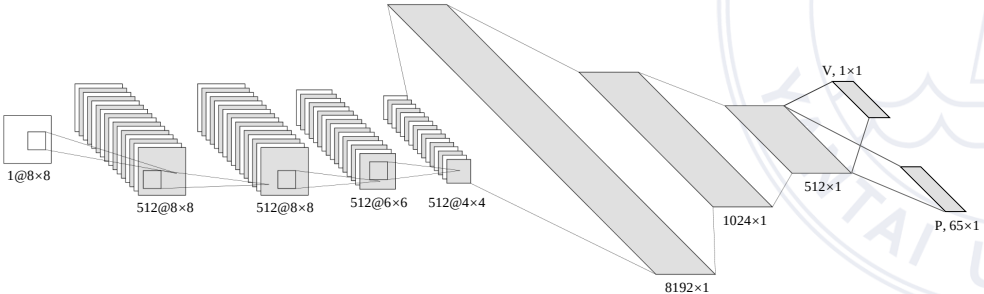

Monte Carlo Tree Search for Policy Improvement

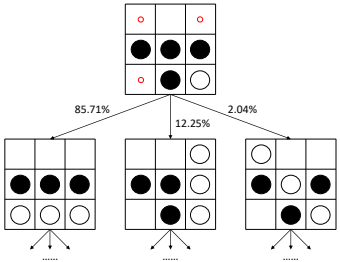

- $Q(s,a)$：在状态 s 下采取动作 a 所得到的预期奖励
- $N(s,a)$：所有模拟中在状态 s 下采取动作 a 的次数
- $P(s,\cdot)=\vec{p}_\theta(s)$：在状态 s 下采取动作的先验概率
- $U(s,a)$：Q value 的置信区间上界

其中 $U(s,a)=Q(s,a)+c_{puct}\cdot P(s,a)\cdot\frac{\sqrt{\Sigma_b N(s,b)}}{1+N(s,a)}$

1: **procedure** MCTS(s,θ)
2: **if** s is *terminal* **then**
3: **return** *game_result*
4: **end if**
5: **if** $s\notin Tree$ **then**
6: $Tree\leftarrow Tree\cup s$
7: $Q(s,\cdot)\leftarrow 0$
8: $N(s,\cdot)\leftarrow 0$
9: $P(s,\cdot)\leftarrow\vec{p}_\theta(s)$
10: $v\leftarrow v_\theta(s)$
11: **return** v
12: **else**
13: $a\leftarrow\arg\max_{a'\in A}U(s,a')$
14: $s'\leftarrow$ get_next_state(s,a)
15: $v\leftarrow$ MCTS(s',θ)
16: $Q(s,a)\leftarrow\frac{N(s,a)\times Q(s,a)+v}{1+N(s,a)}$
17: $N(s,a)\leftarrow N(s,a)+1$
18: **return** v
19: **end if**
20: **end procedure**

Experiments and Analysis

一块 Tesla T4 中训练了 150h，共迭代 120 次，其中成功 29 次，平均每次成功迭代耗时 5.17h

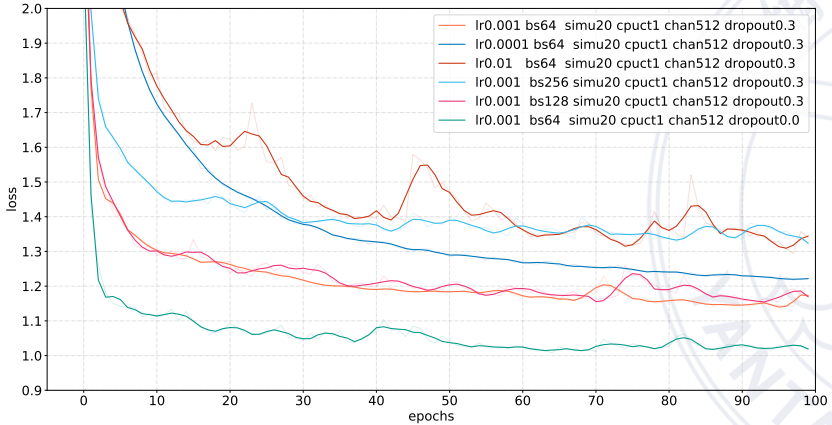

不同超参数配置下的 LOSS 变化曲线

Experiments and Analysis

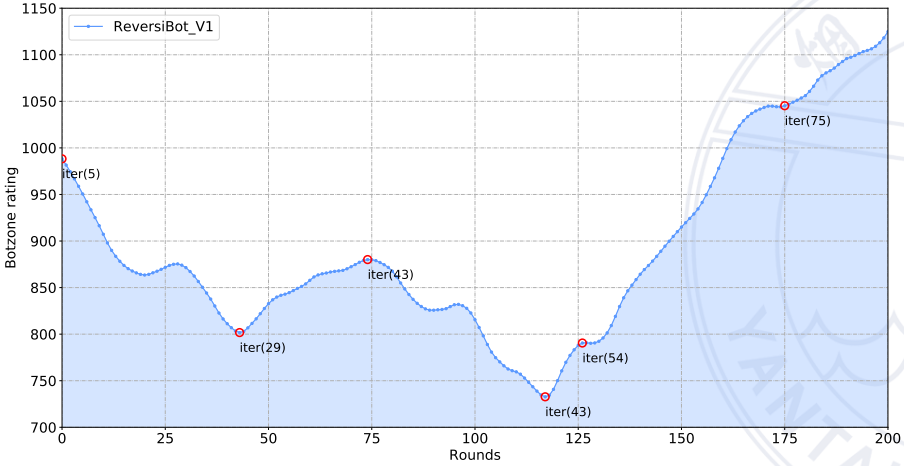

Elo rating 随迭代版本的变化曲线

Experiments and Analysis

不同算法实现的 AI 与本方对局结果

基准	本方胜场数 / 总场数	本方胜率
基于随机策略	80/80	100%
基于可转换棋子最大的贪心	80/80	100%
基于使对方行动力最小的贪心	80/80	100%
极大极小搜索 + Alpha-Beta 剪枝	56/80	70%

Conclusions and Prospect

一些结论

- 人们往往认为机器学习只有在大数据的作用下才能发挥作用，但这是不准确的
- 有些时候设计一个好的自学习算法比数据的输入更重要
- 不需要任何人类知识的输入，它总是和一个与自己棋力相当的 AI 对局并从中总结经验改进自己
- 使用强化学习方法相比于传统算法预测时间短（但需预先进行训练），可提升空间大

期间遇到的问题（已解决）

- Keras 多线程预测产生的线程安全问题（预先将图处理为静态的）
- 多进程 self-play fork 时产生的内存资源消耗严重的问题（减少不必要的内存复制）

展望未来

- 即使后来的 AlphaZero 可以挑战 Dota2 等相对于围棋更为复杂的游戏，但这些游戏相对于现实世界来说仍然属于简单问题
- 步入强人工智能领域还需要走很长的路，也希望我们未来的生活会因此变得更加美好

烟台大学 YANTAI UNIVERSITY

Acknowledgement

- 感谢王建华老师在毕设期间的指导
- 感谢 ACM 实验室卢云宏老师、周世平老师、封玮老师
- 感谢班主任毕远伟老师
- 感谢四年里遇到的各位老师和同学

请多提宝贵意见